

A leíró statisztika jellemzői, diagramok. Nevezetes középértékek.

A leíró statisztika a tömegesen előforduló jelenségekkel, a jelenségekből nyert adatok vizsgálatával, elemzésével (leírásával) foglalkozik. A statisztika egyik fontos feladata az adatok összegyűjtése valamilyen vizsgálandó szempont alapján. Az elemzéshez összegyűjtött adatok halmazát **adatsokaságnak** a vizsgálódás szempontját **ismérvnek** nevezzük.

Ha a vizsgálandó egyedek száma nagyon nagy, akkor nem minden egyedet vizsgálunk meg a tulajdonság alapján, hanem az adatsokaságnak vesszük egy részhalmazát, vagyis az egyedek közül **mintát veszünk**. A megfelelően kiválasztott minta elemzéséből következtethetünk a sokaság adataira. A **reprezentatív mintavétel**nél törekedni kell arra, hogy a vizsgált tulajdonság előfordulása a mintában közelítse a sokaságban való előfordulását.

Pl. közvélemény-kutatás.

Véletlenszerű mintavételnél a sokaság elemei egyenlő valószínűséggel kerülnek a mintába.

Pl. urnából húzás

Egy adat **gyakorisága**: Hányszor fordul elő az az adat.

Egy adat **relatív gyakorisága**: Az összes adat hányad részében fordul elő az adat.

A statisztika szereti átláthatóvá tenni a mintát, ezért találtak ki mindenféle szemléltető módszereket.

Gyakoriság táblázat: A lehetséges értékeket és a hozzájuk tartozó gyakoriságokat tartalmazza.

Átláthatóbbá tehetjük a mintát **osztályba sorolással** is.

Tipikus példa erre, amikor egy dolgozatnál ponthatárokat adunk meg.

0-15: elégtelen

16-26: elégséges

27-34: közepes

35-42: jó

43-53: jeles

A dolgozatok pontszáma:

36, 42, 51, 17, 26, 48, 50, 17, 34, 51, 12, 3, 46,

Végezzük el az osztályba sorolást!

osztályzat	1	2	3	4	5
darabszám	2	3	1	2	5

Osztályköz hossza: Az osztály alsó és felső határa közti különbség.

A példánkban a jeles osztályköz hossza: $53-43=10$ (Ha 10 pontot veszíték, még ötös vagyok)

Osztályközép: Az osztályba tartozó alsó és felső határának számtani közepe.

A példánkban a jeles osztályközépe: $\frac{53+43}{2} = 48$

Az osztály kumulált gyakorisága: Az adott osztályba tartozó adatok száma.

A példánkban a jeles osztály kumulált gyakorisága: 5


Szemléltethetjük az adatokat diagramokon is. Minden diagramnál nagyon fontos, hogy a jelölés legyen egyértelmű.

Oszlopdiagram:

A vízszintes tengelyen az adatfajtáknak megfelelő intervallumokat jelöljük, ezek fölé olyan téglalapokat rajzolunk, amelyeknek területe arányos az adatfajta gyakoriságával. Az adatok egymáshoz való viszonyát ábrázolja.

Az oszlopdiagramnál fontos, hogy


- megnevezzétek a tengelyeket
- legyen beosztás
- egyforma szélesek legyenek az oszlopok



Kördiagram:

A kördiagram elsősorban a relatív gyakoriságról ad információt. Az adatokhoz tartozó relatív gyakoriságok és a megfelelő körcikkek középponti szöge között egyenes arányosság van.

(Ezekon a diagramtípusokon kívül még többféle diagram is van: hisztogram, sávdigram, sodrófa diagram, vonaldiagram)



A diagramok arra jók, hogy szemléltessék az adathalmazt, illetve az adatok egymáshoz és/vagy az egészhez való viszonyát. A különböző **középértékek** pedig azt a célt szolgálják, hogy az adatsokaságunkat leegyszerűsítve egy-egy számmal tudjuk jellemezni. Ezek a középértékek tehát megfelelően alkalmazva jól jelenítik meg a minta valamilyen tulajdonságát, de közben az egyes adatokról nem mondanak semmit. Ezért akkor kapunk pontos képet a mintáról, ha az alábbi statisztikai jellemzőket együttesen vizsgáljuk.

Átlag (számtani közép): Az adatok összege osztva az adatok számával.

Súlyozott átlag: Az adatok összege, amikor egyes adatok szorzóval szerepelnek. (Témazáró jegy duplának számít.)

Medián: Növekvő sorrendben felírva az adatokat a sorban a középső elem. Ha páros az elemszám, akkor a két középső számtani átlaga. A medián előnye, hogy valóban középérték, hiszen ugyanannyi adat nagyobb nála, mint ahány kisebb.

Módusz: A leggyakrabban előforduló elem. Ha a legnagyobb gyakoriság csak egyszer fordul elő az adatsokaságban, akkor az egymóduszú, ha többször is előfordul, akkor többmóduszú, tehát a módusz több elem is lehet, ha ugyanakkora a gyakoriságuk.

A módusz előnye, hogy könnyen meghatározható, hátránya, hogy csak akkor ad használható jellemzést a mintáról, ha a többi adathoz képest sokszor fordul elő.

Terjedelem: A legnagyobb és a legkisebb adat különbsége.

Szórásnégyzet: Az egyes adatok átlagtól való eltérésének négyzetének átlaga. A szórás megmutatja, hogy a minta adatai mennyire térnek el az átlagtól.

Szórás: A szórásnégyzetből vont négyzetgyök.

Nevezetes középértékek:

Legyenek $x_1; x_2; x_3; \dots; x_n$ pozitív számok.

Számtani (aritmetikai) közép: A számok összege osztva a darabszámukkal.

$$A = \frac{\sum_{i=1}^n x_i}{n}$$

Mértani (geometriai) közép: A számok szorzatának annyiadik gyöke, ahány számot összeszoroztunk.

$$G = \sqrt[n]{\prod_{i=1}^n x_i}$$

Négyzetes közép: A számok négyzetének, számtani átlagának négyzetgyöke.

$$N = \sqrt{\frac{\sum_{i=1}^n x_i^2}{n}}$$

Harmonikus közép: A számok reciprokának, számtani átlagának reciproka.

$$H = \frac{n}{\sum_{i=1}^n \frac{1}{x_i}}$$

Tétel: Középértékek közötti összefüggés.

$$H \leq G \leq A \leq N$$

Egyenlőség akkor áll fenn, ha $x_1 = x_2 = x_3 = \dots = x_n$

Bizonyítsuk be két szám esetén a geometriai és az aritmetikai közép közötti összefüggést!

Tétel: $\sqrt{ab} \leq \frac{a+b}{2}$; $a > 0$ és $b > 0$

Bizonyítás:

$$\sqrt{ab} \leq \frac{a+b}{2} \quad / \cdot 2$$

(Megtehetjük, mert mindkét oldal pozitív.)

$$ab \leq \frac{(a+b)^2}{4} \quad / \cdot 4$$

$$4ab \leq (a+b)^2$$

$$4ab \leq a^2 + 2ab + b^2 \quad / -4ab$$

$$0 \leq a^2 - 2ab + b^2$$

$$0 \leq (a-b)^2$$

Ez az egyenlőtlenség pedig mindig igaz. Egyenlőség pedig akkor teljesül, ha $a = b$.

Alkalmazás:

A nevezetes középértékek közötti összefüggést például tudjuk alkalmazni szélsőérték feladatokban.

Például: Az adott kerületű téglalapok közül melyiknek lesz maximális a területe?



$$K = \frac{a+b}{2}$$

$$T = \sqrt{ab}$$

A számtani és mértani közép közötti összefüggés miatt:

$$T \leq K$$

Tehát egy téglalap területe mindig kisebb, vagy egyenlő, mint a kerülete. Egyenlőség akkor áll fenn, ha $a = b$. Ekkor éri el a terület a maximumát. Tehát az adott kerületű téglalapok közül a négyzet lesz a legnagyobb területű.

(Ha fordítva tennénk fel a kérdést, azaz, hogy az adott területű téglalapok közül melyiknek lesz minimális a kerülete, akkor is meg tudnánk találni a választ a fenti módszerrel.)

Egy másik alkalmazás bizonyításban:

Tétel: Egy pozitív számnak és reciprokának összege legalább 2.

Bizonyítás:

Alkalmazzuk a számtani és mértani közép közötti összefüggést egy pozitív számra és a reciprokára.

$$\frac{x + \frac{1}{x}}{2} \geq \sqrt{x \cdot \frac{1}{x}}$$

$$\frac{x + \frac{1}{x}}{2} \geq 1 / \cdot 2$$

$$x + \frac{1}{x} \geq 2$$

Néhány további alkalmazás és matematika történeti vonatkozás:

Statisztika:

- közvélemény-kutatások,
- szavazások,
- gazdasági mutatók,
- osztályátlagok, hiányzási statisztikák,
- felvételi átlagpontok

A statisztika a polgári forradalmak után vált igazi tudománnyá. A kapitalizmusban a államok vezetőin kívül a tőkések is érdekelni kezdték a statisztikai felmérések, egyre komolyabb eszközöket használtak fel adataik feldolgozására hasznuk növelése érdekében.

Az 1890-es Egyesült Államokbeli népszámlálásra Hollerith feltalálta azt a gépet, amely a statisztikai adatokat lyukkártyák elektromos leolvasásával és rendszerezésével dolgozta fel. A gép gyártására Hollerith céget alapított, amelyből később az IBM jött létre.